SISTEMAS PARALELOS

Clase 7 – Programación en pasaje de mensajes // Estándar MPI

Prof Dr Enzo Rucci

FACULTAD DE INFORMATICA
UNIVERSIDAD NACIONAL DE LA PLATA

Agenda de esta clase

- Fundamentos de programación en pasaje de mensajes
- Estándar MPI

FUNDAMENTOS DE PROGRAMACIÓN EN PASAJE DE MENSAJES

Plataformas de memoria distribuida

- Consisten de un conjunto nodos de procesamiento, cada uno con su propio espacio de datos
- Las nodos se comunican intercambiando mensajes tanto para sincronización como para comunicación
- ¿Hay problemas de consistencia?
- Modelo de programación asociado: pasaje de mensajes. ¿Memoria compartida?

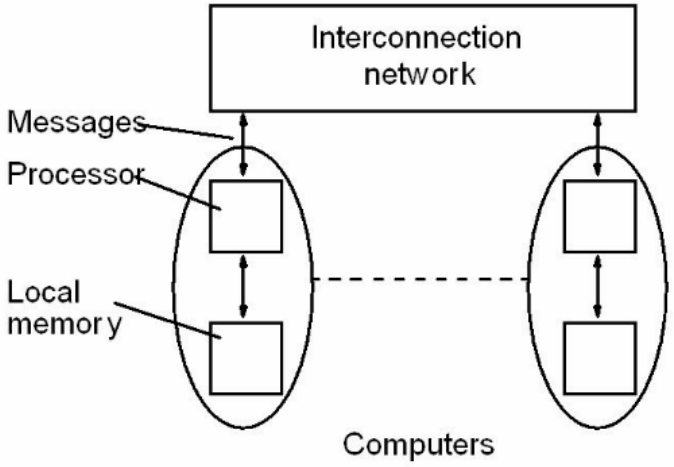

Fundamentos del modelo de pasaje de mensajes

- Consiste de un conjunto de procesos, donde cada uno cuenta con su propio espacio de direcciones.
- Característica clave: Espacio de direcciones particionado.
  - Cada dato pertenece a una partición.
  - Toda interacción requiere la cooperación de dos procesos.

- El intercambio de mensajes sirve para varios propósitos:
  - Intercambio explícito de datos (programador).
  - Sincronizar procesos.
- Generalmente usado en plataformas de memoria distribuida como clusters

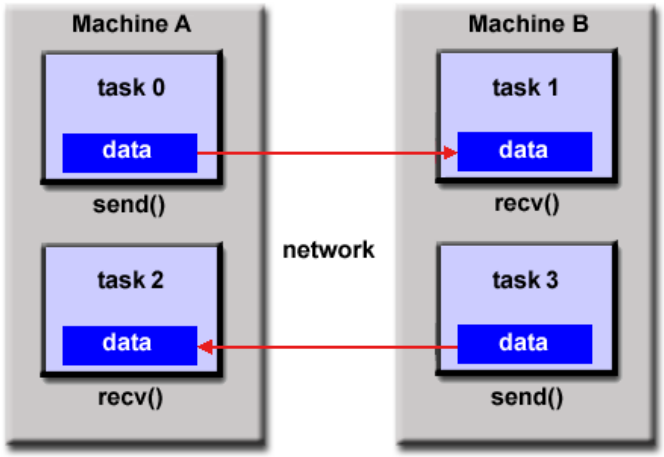

Fundamentos del modelo de pasaje de mensajes

- Programabilidad → En pasaje de mensajes, se trabaja en bajo nivel.
  - El programador es responsable de la distribución de datos y el mapeo de procesos, así como la comunicación entre tareas
  - Difícil de programar, difícil de depurar, difícil de mantener.
  - La mayoría de los programas se escriben siguiendo el modelo *Single Program Multiple Data* (SPMD).
    - No todos ejecutan las mismas instrucciones (sentencias de selección).
    - Los procesos no están sincronizados en la ejecución de cada sentencia.

Fundamentos del modelo de pasaje de mensajes

- Eficiencia → El ajuste (*tuning*) para mejorar el rendimiento puede ser óptimo.
  - Puede manejar el balance de carga, la redistribución de datos y procesos (dinámicamente), replicar datos, entre otras tareas.

- Portabilidad → Existen librerías para facilitar la ejecución de código sobre diferentes arquitecturas (estándares)
  - Buena portabilidad de código, no necesariamente portabilidad de rendimiento.

Fundamentos del modelo de pasaje de mensajes

- Ventajas:
  - El programador tiene total control para lograr sistemas más eficientes y escalables.
  - Puede implementarse eficientemente en muchas arquitecturas paralelas.
  - Más fácil de predecir el rendimiento.

- Desventajas:
  - Mayor complejidad al implementar estos algoritmos para lograr alto rendimiento.

Fundamentos del modelo de pasaje de mensajes: Operaciones Send y Receive

- Los prototipos de las operaciones son:

```
Send (void *sendbuf, int nelems, int dest)
Receive (void *recvbuf, int nelems, int source)
```

- Ejemplo:

```
P0                          P1
a = 100;                    receive(&b, 1, 0)
send(&a, 1, 1);             printf("%d\n", b);
a = 0;
```

- La semántica del Send requiere que en P1 quede el valor 100 (no 0).
- Existe diferentes protocolos para Send y Receive: bloqueante y no bloqueante.

Fundamentos del modelo de pasaje de mensajes: Operaciones Send y Receive

- Cuando una operación de comunicación es *bloqueante:*
  - se devuelve el control al proceso llamador una vez que todos los recursos involucrados (por ejemplo, el buffer de envío/recepción) pueden ser reutilizados → aplica tanto al emisor como al receptor
  - se garantiza que todas transiciones de estados iniciadas por la operación fueron completadas.

- Ociosidad en los procesos.

- Hay dos alternativas:
  - Sin *buffering*.
  - Con *buffering*.

Operaciones Send y Receive – Bloqueantes sin *buffering*

- El send se bloquea hasta que el receptor no termine el receive del mensaje.
- Tiempo ocioso de los procesadores.
- Deadlocks si las sentencias de comunicación no coinciden.

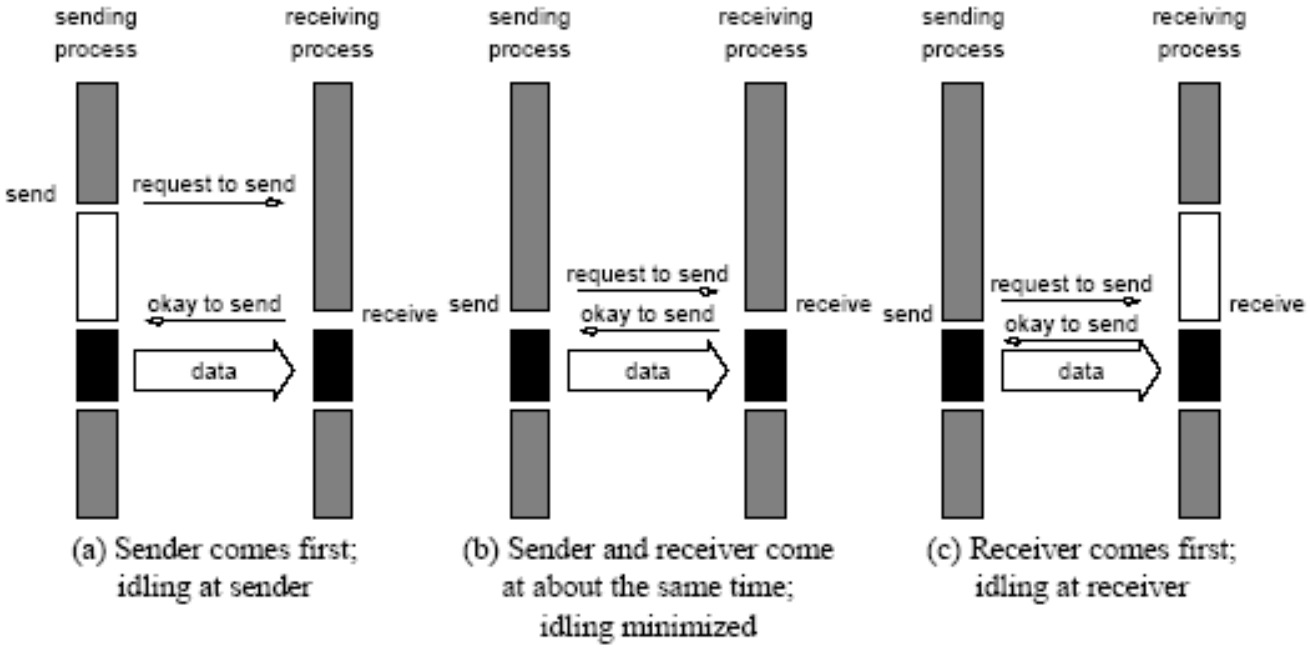

P0
```
send(&a,1,1);
receive(&b,1,1);
```

P1
```
send(&a,1,0);
receive(&b,1,0);
```

Operaciones Send y Receive – Bloqueantes con *buffering*

- El send se bloquea hasta que el mensaje llega a un buffer prealocado del sistema (diferente al del receptor).
- Transmisión del mensaje:
  - Hardware para comunicación asincrónica (sin intervención de la CPU) → se comienza la transmisión al buffer del receptor.
  - Sin hardware especial → el emisor trasmite el mensaje al buffer del receptor y recién ahí se desbloquea.

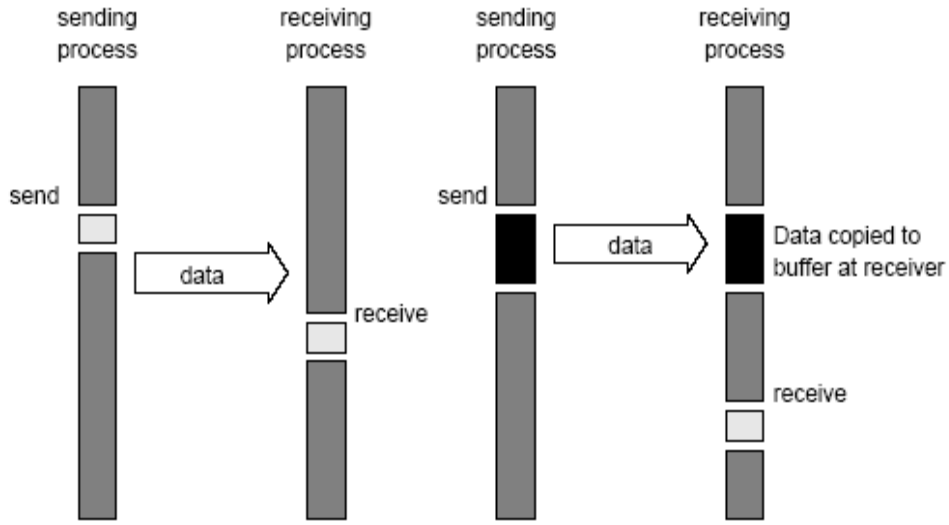

Con hardware específico *Sin hardware específico*

Operaciones Send y Receive – Bloqueantes con *buffering*

- Protocolos con *buffering* reducen el tiempo ocioso de los procesadores pero aumentan el costo por manejo de buffers.
- Tamaño limitado de los buffers → bloquea al send hasta que haya lugar.

```
P0
for (i=0; i<1000; i++){
    produce_data(&a);
    send(&a, 1, 1);
}
```

```
P1
for (i=0; i<1000; i++){
        receive(&a, 1, 0);
        consume_data(&a);
}
```

- *Buffering* reduce la ocurrencia de deadlocks

pero no los evita completamente

```
P0
receive(&a, 1, 1)
send(&b,1, 1)
```

```
P1
receive(&a, 1, 0)
send(&b, 1, 0);
```

```
P0
send(&a,1,1);
receive(&b,1,1);

P1
send(&a,1,0);
receive(&b,1,0);
```

Operaciones Send y Receive – No bloqueantes

- Para evitar overhead (ociosidad o manejo de buffer) se devuelve el control de la operación inmediatamente.
  - No garantiza que los recursos involucrados puedan ser reutilizados
  - No garantiza que todas transiciones de estados iniciadas por la operación hayan sido completadas.
- Requiere un posterior chequeo para asegurarse la finalización de la comunicación → Deja en manos del programador asegurar la semántica del Send.
- Hay dos alternativas:
  - Sin *buffering*: inicia comunicación al llegar al receive.
  - Con *buffering*: el emisor utiliza acceso directo a memoria (DMA) para copiar los datos a un buffer prealocado mientras el proceso continúa su cómputo (reduce el tiempo en que el dato no está seguro).

Operaciones Send y Receive – No bloqueantes

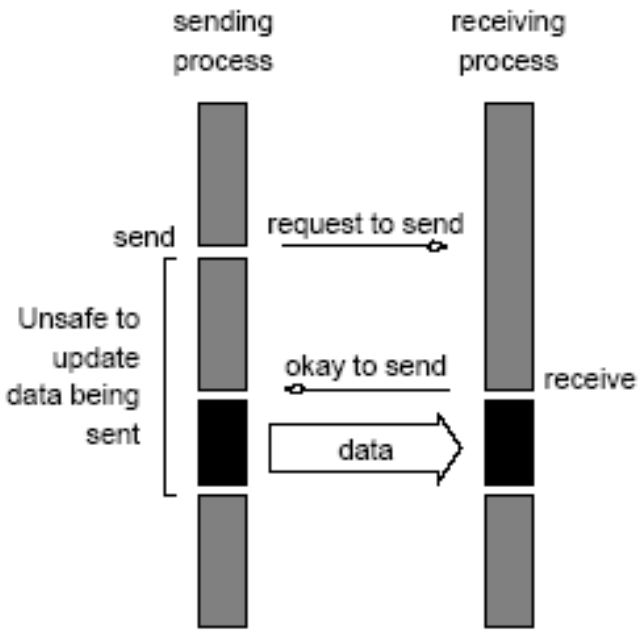

Sin buffering

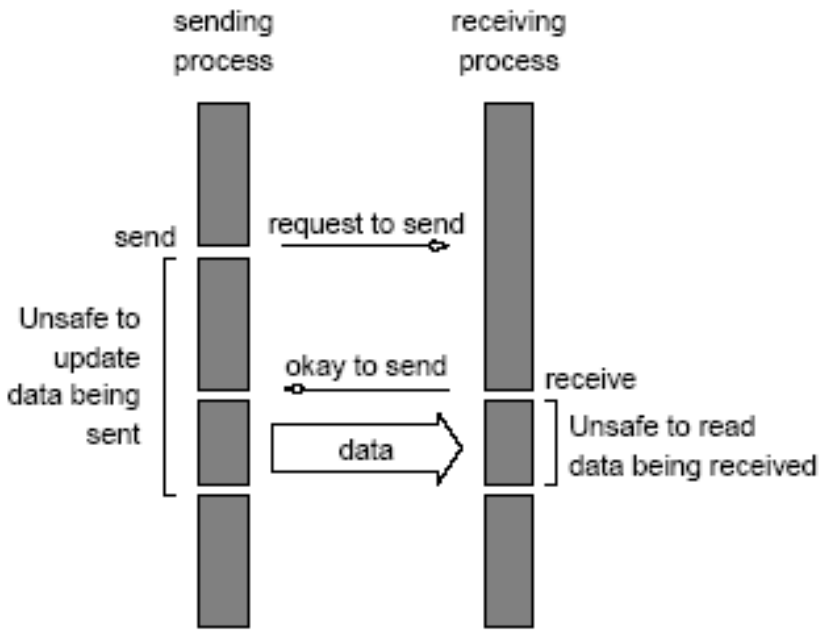

Con buffering

Resumen de opciones para operaciones Send y Receive

	Operaciones bloqueantes	**Operaciones no bloqueantes**
Con buffering	El emisor retoma el control una vez que los datos han sido copiados al buffer	El emisor retoma el control una vez que ha iniciado la transferencia DMA al buffer, aun cuando podría no haberse completado
Sin buffering	El emisor se bloquea hasta que el receptor alcance el receive correspondiente	El emisor envía los datos cuando el receptor alcanza el receive
	La semántica del send y receive está asegurada por la operación correspondiente	El programador debe asegurar explícitamente el cumplimiento de la semántica de las operaciones

ESTÁNDAR MESSAGE PASSING INTERFACE (MPI)

Estándar MPI

- A principios de la década de 1990, existían numerosas librerías para pasaje de mensaje (no compatibles). Un grupo de representantes de las universidades y de la industria se reunieron para desarrollar un estándar para programación basada en pasaje de mensajes.
- MPI define una librería estándar que puede ser empleada desde C o Fortran (y potencialmente desde otros lenguajes).
- Existen diferentes implementaciones de MPI en la actualidad (OpenMPI, MPICH, Intel MPI, IBM MPI, entre otras), aunque no todas soportan la especificación en forma completa → Aspecto a considerar a la hora de elegir la implementación MPI.
- Modelo Single Program Multiple Data (SPMD).
- El estándar MPI define la sintaxis y la semántica de más de 400 rutinas, aunque básicamente con 6 podemos escribir programas paralelos basados en pasaje de mensajes: *MPI_Init, MPI_Finalize, MPI_Comm_size, MPI_Comm_rank, MPI_Send* y *MPI_Recv*

MPI – Inicio y finalización de entorno

- *MPI_Init*: inicializa el entorno MPI. Debe ser invocada por todos los procesos antes que cualquier otro llamado a rutinas MPI.

```
MPI_Init (int *argc, char **argv)
```

```
Algunas implementaciones de MPI requieren argc y argv para inicializar el entorno
```

- *MPI_Finalize*: cierra el entorno MPI. Debe ser invocado por todos los procesos como último llamado a rutinas MPI.

```
MPI_Finalize ()
```

MPI - Comunicadores

- Un comunicador define el dominio de comunicación → qué procesos pueden comunicarse entre sí.
- Son variables del tipo MPI_Comm → almacena información sobre los procesos que pertenecen a él.
- Un proceso puede pertenecer a muchos comunicadores.
- Existe un comunicador que incluye a todos los procesos de la aplicación MPI_COMM_WORLD.
- En cada operación de transferencia se debe indicar el comunicador sobre el que se va a realizar.

MPI – Adquisición de información

- *MPI_Comm_size*: indica la cantidad de procesos en el comunicador.

```
MPI_Comm_size (MPI_Comm comunicador, int *cantidad).
```

- *MPI_Comm_rank*: indica el "*rank*" (identificador) del proceso dentro de ese comunicador.

```
MPI_Comm_rank (MPI_Comm comunicador, int *rank)
```

  - rank es un valor entre [0..cantidad]
  - Cada proceso puede tener un rank diferente en cada comunicador.

MPI – ¡Hola Mundo!

```c
#include <mpi.h>

int main(int argc, char *argv[])
{
    int cantidad, identificador;

    /* iniciar entorno MPI */
    MPI_Init(&argc, &argv);
    /* obtener cantidad de procesos*/
    MPI_Comm_size (MPI_COMM_WORLD, &cantidad);
    /* obtener rank */
    MPI_Comm_rank(MPI_COMM_WORLD, &identificador);
    /* imprimir */
    printf("¡Hola Mundo! Soy %d de %d \n",
            identificador, cantidad);
    /* finalizar entorno MPI */
    MPI_Finalize();
}
```

MPI – ¡Hola Mundo!

```c
#include <mpi.h>

int main(int argc, char *argv[])
{
    int cantidad, identificador;

    /* iniciar entorno MPI */
```

```
enzo@hoja3: ~/sp
enzo@hoja3:~/sp$ mpicc mpi_hello_world.c -o mpi_hello_world -O3 -Wall
mpi_hello_world.c: In function 'main':
mpi_hello_world.c:18: warning: control reaches end of non-void function
enzo@hoja3:~/sp$
enzo@hoja3:~/sp$
enzo@hoja3:~/sp$ mpirun -np 8 mpi_hello_world
Hola Mundo! Soy 5 de 8
Hola Mundo! Soy 6 de 8
Hola Mundo! Soy 7 de 8
Hola Mundo! Soy 2 de 8
Hola Mundo! Soy 1 de 8
Hola Mundo! Soy 3 de 8
Hola Mundo! Soy 4 de 8
Hola Mundo! Soy 0 de 8
enzo@hoja3:~/sp$
```

MPI – Operaciones de comunicación

- MPI soporta:
  - Comunicaciones punto a punto: operaciones de comunicación que involucran a dos procesos → bloqueantes y no bloqueantes
  - Comunicaciones colectivas: operaciones de comunicación que pueden involucrar a dos o más procesos → bloqueantes y no bloqueantes

MPI – Comunicaciones punto a punto bloqueantes

- *MPI_Send*: rutina básica para enviar datos a otro proceso.

```
MPI_Send (void *buf, int cantidad, MPI_Datatype tipoDato,
                int destino, int tag, MPI_Comm comunicador)
```

  - Valor de Tag entre [0..MPI_TAG_UB].

- Existen diferentes variantes para *MPI_Send:*

MPI – Comunicaciones punto a punto bloqueantes

- *MPI_Send*:
  - Retorna el control sólo cuando el buffer del emisor está listo para ser reusado → no significa que el receptor ya haya recibido
  - Podría involucrar uso de buffering o no → depende de la implementación

- *MPI_Bsend (Buffered send)*:
  - Basado en *MPI_Send*
  - Permite implementar buffering a nivel de usuario, ya sea porque el sistema no lo implementa o porque se quiere tener mayor control sobre el mismo

- *MPI_Ssend* (*Synchronic Send).*
  - Retorna el control sólo cuando el buffer del emisor está listo para ser reusado y el proceso receptor ha comenzado a recibir el mensaje

- *MPI_Rsend* (*Ready Send).*
  - Sólo puede ser invocado si el proceso receptor se encuentra listo para recibir. De otro modo, la operación es errónea y el resultado no está garantizado.
  - Puede mejorar el rendimiento de las comunicaciones a costo de una mayor inseguridad en su uso.

MPI – Tipos de datos para comunicaciones

MPI	C
MPI_CHAR	signed char
MPI_SHORT	signed short int
MPI_INT	signed int
MPI_LONG	signed long int
MPI_UNSIGNED_CHAR	unsigned char
MPI_UNSIGNED_SHORT	unsigned short int
MPI_UNSIGNED	unsigned int
MPI_UNSIGNED_LONG	unsigned long int
MPI_FLOAT	float
MPI_DOUBLE	double
MPI_LONG_DOUBLE	long double
MPI_BYTE	
MPI_PACKED	

MPI – Comunicaciones punto a punto bloqueantes

- *MPI_Recv*: rutina básica para recibir datos de otro proceso.

```
MPI_Recv (void *buf, int cantidad, MPI_Datatype tipoDato, int
origen, int tag, MPI_Comm comunicador, MPI_Status *estado)
```

```
- Comodines MPI_ANY_SOURCE y MPI_ANY_TAG.
- Estructura MPI_Status
      typedef struct MPI_Status { int MPI_SOURCE;
                                  int MPI_TAG;
                                  int MPI_ERROR; }
```

- *MPI_Get_count*: rutina para obtener la cantidad de elementos recibidos

```
MPI_Get_count(MPI_Status *estado,
       MPI_Datatype  tipoDato, int *cantidad)
```

MPI – Comunicaciones punto a punto – Casos de deadlock

Ejemplo 1

```
int a[10], b[10], cantProc, id;
MPI_Status estado;
MPI_Comm_size(MPI_COMM_WORLD, &cantProc);
MPI_Comm_rank(MPI_COMM_WORLD, &id);
MPI_Send(a, 10, MPI_INT, (id+1)%cantProc, 1,MPI_COMM_WORLD);
MPI_Recv(b, 10, MPI_INT, (id-1+cantProc)%cantProc,1,MPI_COMM_WORLD, estado);
```

MPI – Comunicaciones punto a punto – Casos de deadlock

Ejemplo 1

```
int a[10], b[10], cantProc, id;
MPI_Status estado;
MPI_Comm_size(MPI_COMM_WORLD, &cantProc);
MPI_Comm_rank(MPI_COMM_WORLD, &id);
MPI_Send(a, 10, MPI_INT, (id+1)%cantProc, 1,MPI_COMM_WORLD);
MPI_Recv(b, 10, MPI_INT, (id-1+cantProc)%cantProc,1,MPI_COMM_WORLD, estado);
```

Ejemplo 2

```
int a[10], b[10], identificador;
MPI_Status estado;
MPI_Comm_rank(MPI_COMM_WORLD, &identificador);
if (identificador == 0) {
   MPI_Send(a, 10, MPI_INT, 1, 1, MPI_COMM_WORLD);
   MPI_Send(b, 10, MPI_INT, 1, 2, MPI_COMM_WORLD);
}
else {
   MPI_Recv(b, 10, MPI_INT, 0, 2, MPI_COMM_WORLD, estado);
   MPI_Recv(a, 10, MPI_INT, 0, 1, MPI_COMM_WORLD, estado);
}
```

MPI – Comunicaciones punto a punto – Casos de deadlock

Código para evitar el deadlock del ejemplo 1

```
int a[10], b[10], cantProc, id;
MPI_Status estado;

MPI_Comm_size(MPI_COMM_WORLD, &cantProc);
MPI_Comm_rank(MPI_COMM_WORLD, &id);

if (id%2 == 1) {
   MPI_Send(a, 10, MPI_INT, (id+1)%cantProc, 1, MPI_COMM_WORLD);
   MPI_Recv(b,10,MPI_INT,(id-1+cantProc)%cantProc,1,MPI_COMM_WORLD,estado);
}
else {
   MPI_Recv(b,10,MPI_INT,(id-1+cantProc)%cantProc,1,MPI_COMM_WORLD,estado);
   MPI_Send(a, 10, MPI_INT, (id+1)%cantProc, 1, MPI_COMM_WORLD);
}
```

MPI – Comunicaciones punto a punto – Casos de deadlock

Ejemplo 3

```
int a[10], b[10], cantProc, id;
MPI_Status estado;
MPI_Comm_size(MPI_COMM_WORLD, &cantProc);
MPI_Comm_rank(MPI_COMM_WORLD, &id);
MPI_Ssend(a, 10, MPI_INT, (id+1)%cantProc, 1,MPI_COMM_WORLD);
MPI_Recv(b, 10, MPI_INT, (id-1+cantProc)%cantProc,1,MPI_COMM_WORLD, estado);
```

MPI – Comunicaciones punto a punto – Casos de deadlock

Ejemplo 3

```
int a[10], b[10], cantProc, id;
MPI_Status estado;
MPI_Comm_size(MPI_COMM_WORLD, &cantProc);
MPI_Comm_rank(MPI_COMM_WORLD, &id);
MPI_Ssend(a, 10, MPI_INT, (id+1)%cantProc, 1,MPI_COMM_WORLD);
MPI_Recv(b, 10, MPI_INT, (id-1+cantProc)%cantProc,1,MPI_COMM_WORLD, estado);
```

Ejemplo 4

```
int a[10], b[10], identificador;
MPI_Status estado;
MPI_Comm_rank(MPI_COMM_WORLD, &identificador);
if (identificador == 0) {
   MPI_Ssend(a, 10, MPI_INT, 1, 1, MPI_COMM_WORLD);
   MPI_Ssend(b, 10, MPI_INT, 1, 2, MPI_COMM_WORLD);
}
else {
   MPI_Recv(b, 10, MPI_INT, 0, 2, MPI_COMM_WORLD, estado);
   MPI_Recv(a, 10, MPI_INT, 0, 1, MPI_COMM_WORLD, estado);
}
```

MPI – Comunicaciones punto a punto – Casos de deadlock

Código para evitar el deadlock del ejemplo 3

```
int a[10], b[10], cantProc, id;
MPI_Status estado;

MPI_Comm_size(MPI_COMM_WORLD, &cantProc);
MPI_Comm_rank(MPI_COMM_WORLD, &id);

if (id%2 == 1) {
   MPI_Ssend(a, 10, MPI_INT, (id+1)%cantProc, 1, MPI_COMM_WORLD);
   MPI_Recv(b,10,MPI_INT,(id-1+cantProc)%cantProc,1,MPI_COMM_WORLD,estado);
}
else {
   MPI_Recv(b,10,MPI_INT,(id-1+cantProc)%cantProc,1,MPI_COMM_WORLD,estado);
   MPI_Ssend(a, 10, MPI_INT, (id+1)%cantProc, 1, MPI_COMM_WORLD);
}
```

MPI – Comunicaciones punto a punto no bloqueantes

- Comienzan la operación de comunicación e inmediatamente devuelven el control (no garantiza que la operación haya finalizado).

```
MPI_Isend (void *buf, int cantidad, MPI_Datatype tipoDato,
           int destino, int tag, MPI_Comm comunicador,
           MPI_Request *solicitud)

MPI_Irecv (void *buf, int cantidad, MPI_Datatype tipoDato,
           int origen, int tag, MPI_Comm comunicador,
           MPI_Request *solicitud)
```

MPI – Comunicaciones punto a punto no bloqueantes

- *MPI_Test*: evalúa si la operación de comunicación finalizó.

```
MPI_Test (MPI_Request *solicitud, int *flag, MPI_Status *estado)
```

- *MPI_Wait*: bloquea al proceso hasta que la operación indicada en el Request haya finalizado.

```
MPI_Wait (MPI_Request *solicitud, MPI_Status *estado)
```

- Este tipo de comunicación permite solapar cómputo con comunicación.
- Es responsabilidad del programador asegurar que la semántica de las operaciones se respete

MPI – Comunicaciones punto a punto no bloqueantes – Ejemplo MPI_Isend

```
int main (int argc, char *argv[]){
       int cant, id, *dato, i;
        MPI_Status estado;

        dato = (int *) malloc (100 * sizeof(int));
        MPI_Init(&argc,&argv);
        MPI_Comm_rank (MPI_COMM_WORLD, &id);

        if (id == 0)   {
            cant = atoi(argv[1])%100;
            MPI_Send(dato,cant,MPI_INT,1,1,MPI_COMM_WORLD);
            for (i=0; i< 100; i++) dato[i]=0;
        } else {
            MPI_Recv(dato,100,MPI_INT,0,1,MPI_COMM_WORLD, &estado);
            MPI_Get_count(&estado, MPI_INT, &cant);
            // Procesa los datos recibidos
         }
        MPI_Finalize();
     }
```

Para usar comunicaciones no bloqueantes, ¿alcanza con cambiar *MPI_Send* por *MPI_Isend*?

MPI – Comunicaciones punto a punto no bloqueantes – Ejemplo MPI_Isend

```
int main (int argc, char *argv[]){
       int cant, id, *dato, i;
        MPI_Status estado; MPI_Request req;

        dato = (int *) malloc (100 * sizeof(int));
        MPI_Init(&argc,&argv);
        MPI_Comm_rank (MPI_COMM_WORLD, &id);

        if (id == 0)   {
            cant = atoi(argv[1])%100;
            MPI_Isend(dato,cant,MPI_INT,1,1,MPI_COMM_WORLD, &req);
            // Otro cómputo
            MPI_Wait(&req,&estado);
            for (i=0; i< 100; i++) dato[i]=0;
        } else {
            MPI_Recv(dato,100,MPI_INT,0,1,MPI_COMM_WORLD, &estado);
            MPI_Get_count(&estado, MPI_INT, &cant);
            // Procesa los datos recibidos
         }
        MPI_Finalize();
      }
```

MPI – Comunicaciones punto a punto no bloqueantes – Ejemplo MPI_Irecv

```
int main (int argc, char *argv[]){
            int id, *dato, i, flag;
            MPI_Status estado;
            MPI_Request req;

            dato = (int *) malloc (100 * sizeof(int));
            MPI_Init(&argc,&argv);
            MPI_Comm_rank (MPI_COMM_WORLD, &id);

            if (id == 0)   {
                // Inicializa datos a enviar
                MPI_Send(dato,cant,MPI_INT,1,1,MPI_COMM_WORLD);
            } else {
                MPI_Irecv(dato,100,MPI_INT,0,1,MPI_COMM_WORLD ,&req);
                MPI_Test(&req, &flag,&estado);
                while (!flag){
                   //Trabaja mientras espera
                   MPI_Test(&req, &flag,&estado);
                  }
                // Procesa los datos recibidos
              }
            MPI_Finalize();
          }
```

MPI – Comunicaciones punto a punto – Orden y *fairness*

- Sobre orden:
  - MPI asegura que los mensajes no se *sobrepasarán* entre ellos.
  - Si un proceso envía 2 mensajes seguidos a un mismo receptor (M1 y M2), y ambos coinciden con el mismo receive, el orden de recepción será: M1, M2.
  - Si un proceso ejecuta 2 receive seguidos (R1 y R2), y hay un mensaje pendiente que coincide con ambos, R1 recibirá antes que R2.

- Sobre *fairness* (justicia):
  - MPI no asegura fairness → es responsabilidad del programador que un proceso no sufra *inanición*
  - Ejemplo: P0 le envía un mensaje a P2. Sin embargo, P1 envía otro mensaje a P2 que compite con el de P0 (coincide con el receive). P2 sólo recibirá uno de los 2 mensajes.

MPI – Consulta de comunicaciones pendientes

- Es posible consultar si hay comunicaciones pendiente y algunos de sus datos
- *MPI_Probe*: bloquea al proceso hasta que llegue un mensaje que cumpla con el origen y el tag.

```
MPI_Probe (int origen, int tag, MPI_Comm comunicador,
                MPI_Status *estado)
```

- *MPI_Iprobe*: chequea por el arribo de un mensaje que cumpla con el origen y tag.

```
MPI_Iprobe (int origen, int tag, MPI_Comm comunicador,
                        int *flag, MPI_Status *estado)
- Comodines en Origen y Tag.
```

MPI – Comunicaciones colectivas

- MPI provee un conjunto de funciones para realizar operaciones colectivas, sobre un grupo de procesos asociado con un comunicador.
  - *No sólo facilitan la programación sino que mejoran el rendimiento.*
  - Todos los procesos del comunicador deben llamar a la rutina colectiva.

- Tipos de operaciones colectivas:

  - Sincronización: los procesos se bloquean hasta que todos hayan llegado a determinado punto del programa
  - Transferencia de datos: *broadcast*, *scatter*, *gather* y sus variantes
  - Computaciones colectivas: operaciones de reducción

MPI – Comunicaciones colectivas – Sincronización por barrera

- Sincronización en una barrera.

```
MPI_Barrier(MPI_Comm comunicador)
```

MPI – Comunicaciones colectivas - Broadcast

- *Broadcast*: un proceso envía el mismo mensaje a todos los otros procesos del comunicador.

```
MPI_Bcast (void *buf, int cantidad, MPI_Datatype tipoDato,
                    int origen, MPI_Comm comunicador)
```

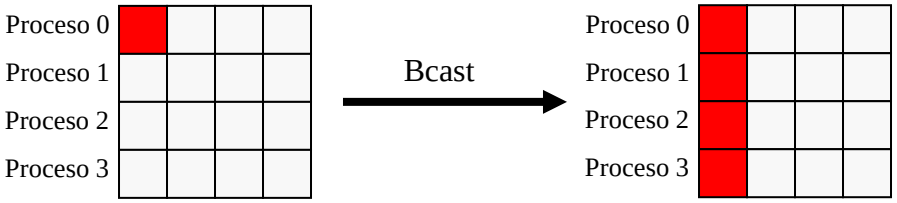

MPI – Comunicaciones colectivas - Gather

- *Gather*: recolecta un vector de datos de cada proceso del comunicador (inclusive el destino) y los concatena en orden para dejar el resultado en un único proceso.

```
MPI_Gather (void *sendbuf, int cantEnvio,
    MPI_Datatype tipoDatoEnvio, void*recvbuf, int cantRec,
    MPI_Datatype tipoDatoRec, int destino,
    MPI_Comm comunicador)
```

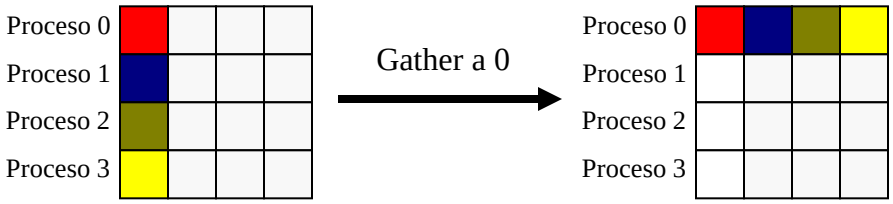

MPI – Comunicaciones colectivas - Gatherv

- Gather requiere que todos los procesos aporten la misma cantidad de datos. Para casos en los que cada proceso envía una cantidad diferente, MPI cuenta con la variante Gatherv

```
MPI_Gatherv (void *sendbuf, int cantEnvio,
    MPI_Datatype tipoDatoEnvio, void*recvbuf, int *cantsRec,
    int *desplazamientos, MPI_Datatype tipoDatoRec,
    int destino, MPI_Comm comunicador)
```

MPI – Comunicaciones colectivas - Allgather

- *Allgather*: funciona como el Gather sólo que el resultado es enviado a todos los procesos.

```
MPI_AllGather (void *sendbuf, int cantEnvio,
    MPI_Datatype tipoDatoEnvio, void*recvbuf, int cantRec,
    MPI_Datatype tipoDatoRec, MPI_Comm comunicador)
```

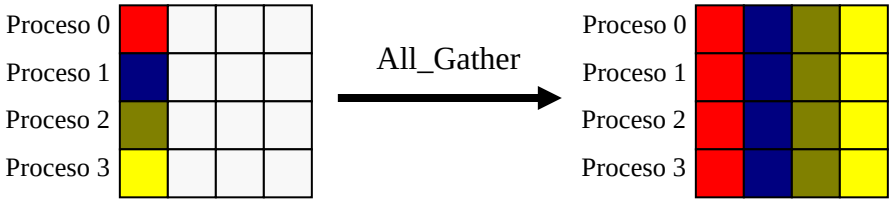

MPI – Comunicaciones colectivas - Allgatherv

- MPI ofrece una variante de *Allgather* para aquellos casos en cada proceso puede enviar una cantidad diferente de datos.

```
MPI_Allgatherv (void *sendbuf, int cantEnvio,
    MPI_Datatype tipoDatoEnvio, void*recvbuf,
    int *cantsRec, int *desplazamientos,
    MPI_Datatype tipoDatoRec, MPI_Comm comunicador)
```

MPI – Comunicaciones colectivas - Scatter

- Scatter: reparte un vector de datos entre todos los procesos (inclusive el mismo dueño del vector) de forma equitativa.

```
MPI_Scatter (void *sendbuf, int cantEnvio,
    MPI_Datatype tipoDatoEnvio, void*recvbuf, int cantRec,
    MPI_Datatype tipoDatoRec, int origen, MPI_Comm comunicador)
```

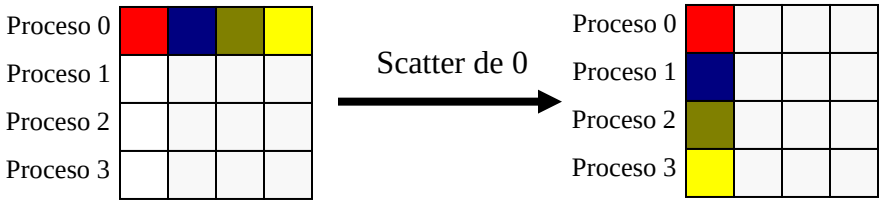

MPI – Comunicaciones colectivas - Scatterv

- Al igual que con Gather, MPI ofrece una variante de Scatter para aquellos casos en que hay que repartir una cantidad diferente a cada proceso.

```
MPI_Scatterv (void *sendbuf, int *cantsEnvio,
    int *desplazamientos, MPI_Datatype tipoDatoEnvio,
    void*recvbuf, int cantRec, MPI_Datatype tipoDatoRec,
    int origen, MPI_Comm comunicador)
```

MPI – Comunicaciones colectivas – All to all

- All to all: cada proceso envía una parte de sus datos a cada uno de los otros procesos (incluso a él mismo) y recibe de ellos una parte.
  - Todas las porciones son del mismo tamaño
  - Es equivalente a realizar un Scatter + Gather.

```
MPI_Alltoall (void *sendbuf, int cantEnvio,
    MPI_Datatype tipoDatoEnvio, void*recvbuf, int cantRec,
    MPI_Datatype tipoDatoRec, MPI_Comm comunicador)
```

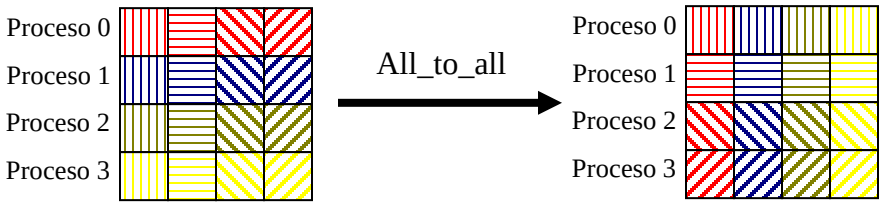

MPI – Comunicaciones colectivas – All to all

- MPI cuenta con la variante Alltoallv para los casos en que los procesos pueden enviar y recibir porciones de tamaño diferente.

```
MPI_Alltoallv (void *sendbuf, int *cantsEnvio, int *despEnvio,
    MPI_Datatype tipoDatoEnvio, void*recvbuf, int *cantsRec,
    int *despRec, MPI_Datatype tipoDatoRec,
    MPI_Comm comunicador)
```

MPI – Comunicaciones colectivas – Reducciones

- Reducción de todos a uno: combina los elementos enviados por cada uno de los procesos (inclusive el destino) aplicando una cierta operación.

```
MPI_Reduce (void *sendbuf, void *recvbuf, int cantidad,
                    MPI_Datatype tipoDato, MPI_Op operación,
                    int destino , MPI_Comm comunicador)
```

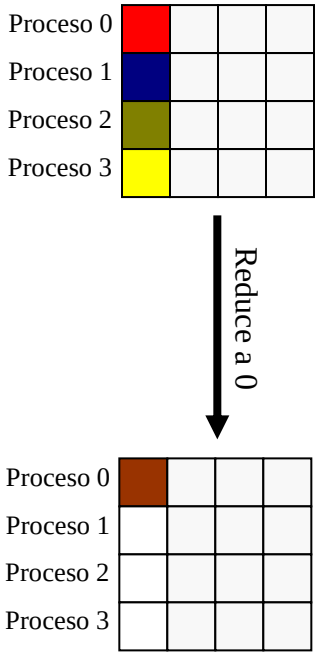

MPI – Comunicaciones colectivas – Reducciones

- Reducción de todos a uno: combina los elementos enviados por cada uno de los procesos (inclusive el destino) aplicando una cierta operación.

```
MPI_Reduce (voic
```

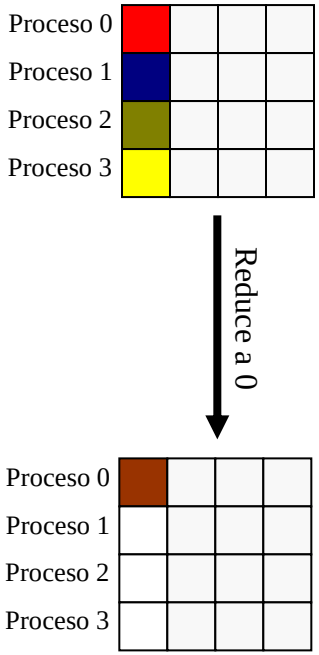

Operation	Meaning	Datatypes
MPI_MAX	Maximum	C integers and floating point
MPI_MIN	Minimum	C integers and floating point
MPI_SUM	Sum	C integers and floating point
MPI_PROD	Product	C integers and floating point
MPI_LAND	Logical AND	C integers
MPI_BAND	Bit-wise AND	C integers and byte
MPI_LOR	Logical OR	C integers
MPI_BOR	Bit-wise OR	C integers and byte
MPI_LXOR	Logical XOR	C integers
MPI_BXOR	Bit-wise XOR	C integers and byte
MPI_MAXLOC	max-min value-location	Data-pairs
MPI_MINLOC	min-min value-location	Data-pairs

MPI – Comunicaciones colectivas – Reducciones

- Reducción de todos a todos: el resultado de la operación de reducción es enviado a todos los procesos.

```
MPI_Allreduce (void *sendbuf, void *recvbuf, int cantidad,
               MPI_Datatype tipoDato, MPI_Op operación,
               MPI_Comm comunicador)
```

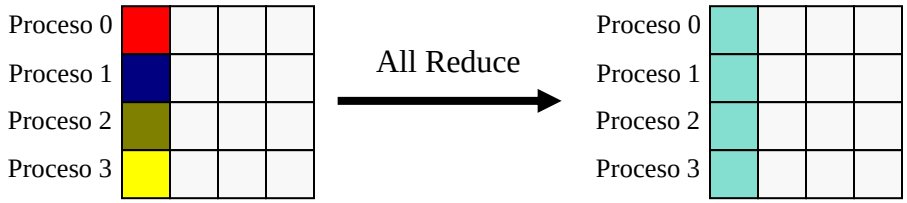

MPI – Ejemplo: reducción a suma de vector con comunicaciones punto a punto

```
1  #include <stdio.h>
2  #include <stdlib.h>
3  #include <mpi.h>
4
5  #define MAX_SIZE 2000
6  #define COORDINATOR 0
7
8  int main(int argc, char* argv[]){
9      int i, numProcs, rank, size, stripSize, localSum=0, sum=0;
10     int array[MAX_SIZE];
11     MPI_Status status;
12
13     /* Lee parámetros de la línea de comando */
14     size = atoi(argv[1]);
15     size = (size < MAX_SIZE ? size : MAX_SIZE);
16
17     MPI_Init(&argc,&argv);
18
19     MPI_Comm_size(MPI_COMM_WORLD,&numProcs);
20     MPI_Comm_rank(MPI_COMM_WORLD,&rank);
21
22     if (rank == COORDINATOR)
23         for (i=0; i<size ; i++)
24             array[i] = i+1;
```

MPI – Ejemplo: reducción a suma de vector con comunicaciones punto a punto

```
26      stripSize = size / numProcs;
27
28      /* distribuir datos*/
29      if (rank==COORDINATOR){
30          for (i=1; i<numProcs; i++)
31              MPI_Send(array+i*stripSize, stripSize, MPI_INT, i, 0, MPI_COMM_WORLD);
32      } else
33          MPI_Recv(array, stripSize, MPI_INT, COORDINATOR, 0, MPI_COMM_WORLD, &status);
34
35      /* computar suma parcial */
36      for (i=0; i<stripSize; i++)
37          localSum += array[i];
38
39      /* recolectar resultados parciales*/
40      if (rank==COORDINATOR){
41          sum = localSum;
42          for (i=1; i<numProcs; i++) {
43              MPI_Recv(&localSum, 1, MPI_INT, i, 1, MPI_COMM_WORLD, &status);
44              sum += localSum;
45          }
46      } else
47          MPI_Send(&localSum, 1, MPI_INT, COORDINATOR, 1, MPI_COMM_WORLD);
48
49      MPI_Finalize();
50
51      if (rank==COORDINATOR)
52          printf("Sum=%d\n",sum);
```

MPI – Ejemplo: reducción a suma de vector con comunicaciones colectivas

```
1  #include <stdio.h>
2  #include <stdlib.h>
3  #include <mpi.h>
4
5  #define MAX_SIZE 2000
6  #define COORDINATOR 0
7
8  int main(int argc, char* argv[]){
9      int i, numProcs, rank, size, stripSize, localSum=0, sum=0;
10     int array[MAX_SIZE];
11     MPI_Status status;
12
13     /* Lee parámetros de la línea de comando */
14     size = atoi(argv[1]);
15     size = (size < MAX_SIZE ? size : MAX_SIZE);
16
17     MPI_Init(&argc,&argv);
18
19     MPI_Comm_size(MPI_COMM_WORLD,&numProcs);
20     MPI_Comm_rank(MPI_COMM_WORLD,&rank);
21
22     if (rank == COORDINATOR)
23         for (i=0; i<size ; i++)
24             array[i] = i+1;
```

MPI – Ejemplo: reducción a suma de vector con comunicaciones colectivas

```
26      stripSize = size / numProcs;
27
28      /* distribuir datos*/
29      if (rank==COORDINATOR){
30          for (i=1; i<numProcs; i++)
31              MPI_Send(array+i*stripSize, stripSize, MPI_INT, i, 0, MPI_COMM_WORLD);
32      } else
33          MPI_Recv(array, stripSize, MPI_INT, COORDINATOR, 0, MPI_COMM_WORLD, &status);
34
35      /* computar suma parcial */
36      for (i=0; i<stripSize; i++)
37          localSum += array[i];
38
39      /* recolectar resultados parciales*/
40      if (rank==COORDINATOR){
41          sum = localSum;
42          for (i=1; i<numProcs; i++) {
43              MPI_Recv(&localSum, 1, MPI_INT, i, 1, MPI_COMM_WORLD, &status);
44              sum += localSum;
45          }
46      } else
47          MPI_Send(&localSum, 1, MPI_INT, COORDINATOR, 1, MPI_COMM_WORLD);
48
49      MPI_Finalize();
50
51      if (rank==COORDINATOR)
52          printf("Sum=%d\n",sum);
```

Scatter

Reduce

MPI – Ejemplo: reducción a suma de vector con comunicaciones colectivas

```
25      stripSize = size / numProcs;
26
27      MPI_Scatter(array, stripSize, MPI_INT, array, \
28                          stripSize, MPI_INT, COORDINATOR, MPI_COMM_WORLD);
29
30      for (i=0; i<stripSize; i++)
31          localSum += array[i];
32
33      MPI_Reduce(&localSum, &sum, 1, MPI_INT, MPI_SUM, COORDINATOR, MPI_COMM_WORLD);
34
35      MPI_Finalize();
```

MPI – Grupos y comunicadores

- En ocasiones, las operaciones de comunicación entre los procesos de un programa se realizan entre subconjunto de ellos → MPI provee mecanismos para dividir el grupo de procesos asociado a un comunicador en varios subgrupos (cada uno con su correspondiente comunicador)

```
MPI_Comm_split(MPI_Comm comm, int color, int key,
               MPI_Comm *newcomm)
```

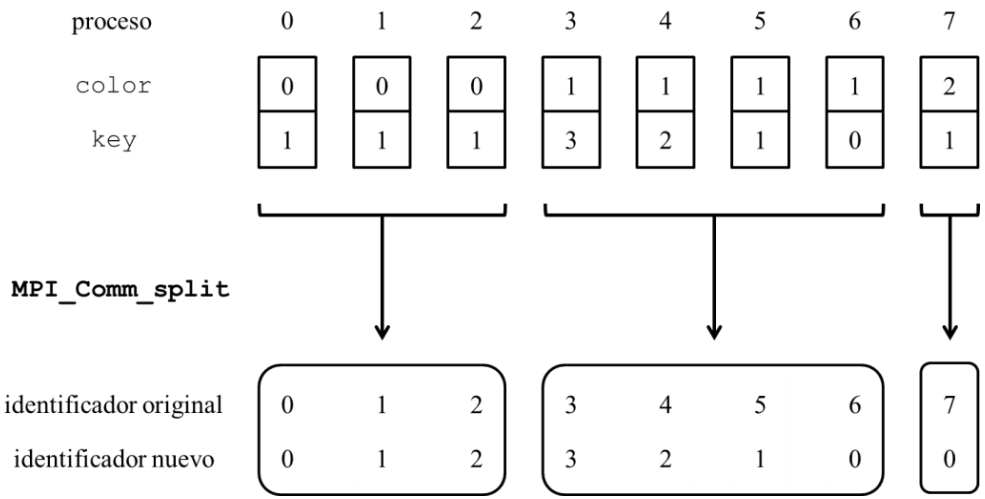

MPI-2 y MPI-3

- MPI-1 fue introducida en 1994, aunque el foro de MPI continuó trabajando en correcciones y extensiones de esa primera versión.

- MPI-2 fue publicado en 1998 como una versión superadora de la primera. Incluyó funcionalidad para:
  - Generación dinámica de procesos
  - Comunicaciones one-sided
  - Soporte para comunicaciones colectivas de a grupos
  - Soporte para C++
  - E/S paralela

- MPI-3 fue aprobado en 2012. Incluyó funcionalidad para:
  - Comunicaciones colectivas no bloqueantes
  - Más soporte para comunicaciones one-sided
  - Mas soporte para comunicaciones colectivas de a grupos
  - Soporte para Fortran 2008

MPI hoy

- La mayoría de las implementaciones sigue la versión 1.2 del estándar.
- *Bindings* disponibles a otros lenguajes:
  - Python: mpi4py, ScientificPython (no SciPy)
  - Java: Java-MPI
  - R: Rmpi
  - Rust: rsmpi
  - Julia: MPI.jl

Bibliografía usada para esta clase

- MPI tutorial. Blaise Barney, Lawrence Livermore National Laboratory. https://computing.llnl.gov/tutorials/mpi/
- Capítulo 6, An Introduction to Parallel Computing. Design and Analysis of Algorithms (2da Edition). Grama A., Gupta A., Karypis G. & Kumar V. (2003) Inglaterra: Pearson Addison Wesley.
- Capítulo 5, Parallel Programming for Multicore and Cluster Systems. Rauber, T. & Rünger, G. (2010). EEUU: Springer-Verlag Berlin Heidelberg.
- Capítulo 10 y 11, Introduction to HPC for Scientists and Engineers. Hager, G. & Wellein, G. (2011) EEUU: CRC Press.